

Caratterizzazione e Clustering di Matrici di Correlazione ADNI-2 Tramite Distribuzione di Wishart

Carlo Mengucci

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

28 Novembre 2017

Obiettivi dello Studio

- Organizzazione ed esplorazione preliminare della sezione del DataBase ADNI-2 contenente le matrici di correlazione di *Resting State* di soggetti sani e affetti da Alzheimer
- Giustificazione analitica dell'utilizzo della *Distribuzione di Wishart* come ipotesi nulla per la caratterizzazione
- Sviluppo di un algoritmo in grado di separare i soggetti sani dai malati e di individuare un gruppo di significativo di *features* per il clustering

ADNI-2

- 404 soggetti totali
- Ad ogni soggetto è associata una matrice di correlazione $N \times N$, $N = 549$
- Ognuno degli N elementi rappresenta un *Macrovoxel* di cui è estratta la correlazione *topologica* rispetto a tutte le altre componenti del sistema
- Ogni *Macrovoxel* è definito su un insieme di $3 \cdot 10^3$ Voxel
- Dei 404 soggetti sono stati utilizzati soltanto gli ultimi 300 a causa di discrepanze tra procedure di normalizzazione tra due sezioni distinte individuabili all'interno del DataBase

Forma Analitica ^a

^aHardle, Wolfgang and Leopold Simar. 2012. *Applied Multivariate Statistical Analysis*. Heidelberg: Springer Berlin Heidelberg

- La distribuzione di Wishart consiste in una famiglia di distribuzioni per *matrici simmetriche definite positive*
- Siano $X_1 \dots X_n$ vettori indipendenti $N_p(0, \Sigma)$ e tali da formare una matrice di dati $p \times n$, $X = [X_1 \dots X_n]$. La distribuzione di *matrici random* $p \times p$, $M = XX' = \sum_{i=1}^n X_i X_i'$ è una distribuzione di Wishart.

Forma Analitica ^a

^aHardle, Wolfgang and Leopold Simar. 2012. *Applied Multivariate Statistical Analysis*. Heidelberg: Springer Berlin Heidelberg

- La matrice random $M_{p \times p} = \sum_{i=1}^n X_i X_i'$ segue una distribuzione di Wishart a n gradi di libertà e *matrice di covarianza* Σ ed è definita $M \sim W_p(n, \Sigma)$. Per $n \geq p$ la *pdf* di M assume la forma :

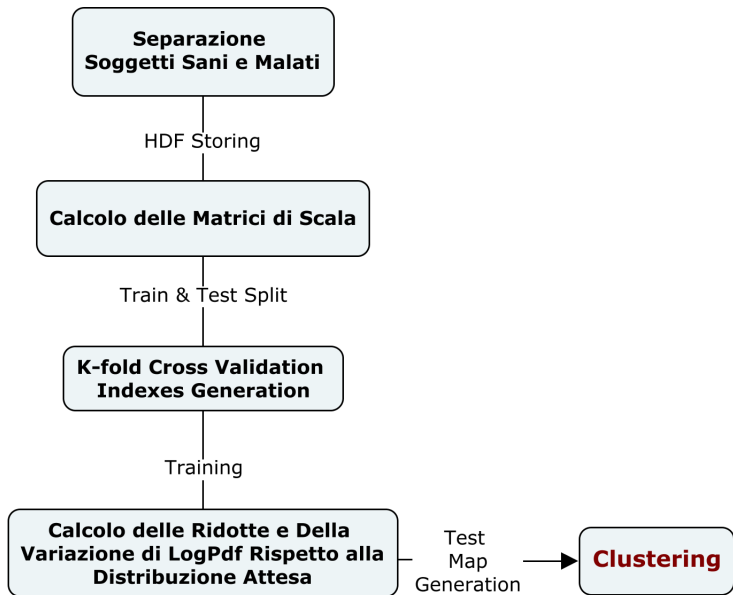
$$f(M) = \frac{1}{2^{\frac{np}{2}} \Gamma_p(\frac{n}{2}) \|\Sigma\|^{\frac{n}{2}}} \|M\|^{\frac{n-p-1}{2}} \exp[-\frac{1}{2} \text{trace}(\Sigma^{-1}M)] \quad (1)$$

- La Wishart può essere interpretata come l'estensione multivariata di una distribuzione χ^2

Definizione delle Condizioni di Applicazione

- Le matrici di correlazione sono per definizione simmetriche definite positive
- Il numero n di gradi di libertà del sistema è dato dal campionamento ($n = 3 \cdot 10^3$) del singolo Macrovoxel
- Utilizzando come matrice di scala la matrice data dalla media delle matrici di correlazione delle due categorie di soggetti, è possibile ricostruire la Wishart attesa per le categorie stesse.


Pipeline



Calcolo delle Ridotte: Approfondimento

- *Definizione*: sia A una matrice $n \times n$, una sottomatrice $k \times k$ di A ottenuta eliminando $n - k$ righe e le stesse $n - k$ colonne di A è detta *sottomatrice principale*.
- *Teorema*: Se A è simmetrica definita positiva, ogni sottomatrice principale di A è anch'essa simmetrica definita positiva.
- Queste proprietà permettono di calcolare il peso che ogni componente del sistema possiede, in termini di variazione di LogPdf rispetto alla matrice di scala generatrice della distribuzione attesa.
- Vengono cioè valutate N variazioni di LogPdf su N sottomatrici principali di dimensioni $(N - 1) \times (N - 1)$.

Clustering



LogPdf Distribution

